

Documentação técnica detalhada

Pipeline estatístico Steam e dashboard Streamlit

Arquivos documentados:

`steam_calculo.py`

`steam_streamlit.py`

Objetivo

Explicar detalhadamente todas as decisões implementadas: reparo do CSV, limpeza, criação de variáveis, definição de sucesso, estatísticas, arquivos gerados, visualizações, filtros, interpretação e limitações.

Resumo executivo do trabalho realizado

Resultado geral

O projeto foi dividido em duas responsabilidades. O arquivo `steam_calculo.py` transforma o CSV bruto em uma base limpa e em tabelas estatísticas reutilizáveis. O arquivo `steam_streamlit.py` consome essas tabelas e apresenta a análise de negócio em um dashboard interativo com Matplotlib.

Números atuais

O pipeline reteve 106,244 jogos limpos, identificou 89,000 jogos comerciais pagos e classificou 8,849 como sucesso. O limite de vendas altas é 35,000 proprietários estimados e a taxa-base de sucesso é 9.94%.

Princípio de projeto

A análise de negócio foi retirada do script de processamento. Assim, o pipeline fica responsável por fatos, métricas e arquivos; o Streamlit fica responsável por interpretação, recomendações, visualização e interação.

Arquitetura completa do projeto

Fluxo entre origem, processamento, arquivos analíticos e dashboard



Separação de responsabilidades: o primeiro script prepara dados e estatísticas; o segundo interpreta e apresenta os resultados.

1. Problema de qualidade encontrado no CSV

Defeito estrutural

O arquivo original possui linhas sem o valor AppID e um cabeçalho combinado chamado DiscountDLC count. Por isso, as primeiras colunas são lidas em posições erradas: o nome aparece em AppID, a data aparece em Name, a faixa de proprietários aparece em Release date e assim por diante até Price.

Como foi diagnosticado

Foi comparado o cabeçalho com exemplos reais. Um registro mostrava AppID = nome do jogo, Name = data e Release date = faixa de proprietários. A partir de About the game, o segundo defeito do cabeçalho recompõe o alinhamento.

Solução

COLONAS_DESLOCADAS funciona como contrato de reparo. carregar_e_reparar lê somente as colunas necessárias e cria um novo DataFrame com os nomes corretos. O AppID real não pode ser recuperado porque ele não está presente nas linhas.

Impacto

Sem esse reparo, preço, proprietários, pico de jogadores e idade seriam interpretados incorretamente. Qualquer conclusão estatística seria inválida.

2. Constantes e reparo da origem

As constantes centralizam caminhos, data de corte e critérios mínimos. O mapeamento abaixo documenta explicitamente onde cada campo correto foi encontrado no CSV defeituoso.

```

FONTE = Path("steam_dataset.csv")
DIRETORIO_SAIDA = Path("steam_analysis")
DATA_ANALISE = pd.Timestamp("2026-06-12")
MIN_AVALIACOES_PARA_NOTA = 20
TAMANHO_MIN_GRUPO = 100

COLUNAS_DESLOCADAS = {
    "Name": "AppID",
    "Release date": "Name",
    "Estimated owners": "Release date",
    "Peak CCU": "Estimated owners",
    "Required age": "Peak CCU",
    "Price": "Required age",
    "Windows": "Windows",
    "Genres": "Genres",
    "Tags": "Tags",
}

def carregar_e_reparar():
    colunas_brutas = list(dict.fromkeys(COLUNAS_DESLOCADAS.values()))
    bruto = pd.read_csv(FONTE, usecols=colunas_brutas, low_memory=False)
    return pd.DataFrame({
        correto: bruto[deslocado]
        for correto, deslocado in COLUNAS_DESLOCADAS.items()
    })
```

3. Limpeza: datas, proprietários e números

Datas

Release date é convertida com `pd.to_datetime(errors='coerce')`. Valores inválidos tornam-se NaT e são removidos posteriormente. A `DATA_ANALISE` impede que lançamentos futuros entrem na comparação.

Faixas de proprietários

Estimated owners tem formato como 0 - 20000. Uma expressão regular extrai os limites inferior e superior. O pipeline cria `owners_lower`, `owners_upper` e `owners_midpoint`. O ponto médio é usado como aproximação numérica para vendas.

Conversão numérica

A função `numerico` usa `pd.to_numeric(errors='coerce')`. Isso padroniza Peak CCU, idade, preço, Metacritic, avaliações, recomendações e tempo médio. Valores impossíveis tornam-se ausentes em vez de interromper a execução.

Limitação importante

O ponto médio de uma faixa ampla não é uma contagem exata. Ele permite comparações e agrupamentos, mas não deve ser tratado como receita real.

4. Variáveis derivadas

Avaliações

review_count soma avaliações positivas e negativas. positive_ratio divide positivas pelo total somente quando existe ao menos uma avaliação.

Plataformas

platform_count soma os indicadores booleanos Windows, Mac e Linux. O valor varia de zero a três.

Faixa de preço

price_band agrupa preço em Free, 0 – 5, 5-10, 10 – 20, 20-30, 30 – 60e60+. Isso reduz ruído e permite comparar posicionamentos comerciais.

Ano de lançamento

release_year é extraído de release_date e alimenta a análise temporal no dashboard.

Modo de jogo

play_mode procura textos de multiplayer e single-player em Categories. Multiplayer tem prioridade quando ambas as expressões aparecem. Sem evidência, o registro recebe Unspecified.

5. Filtros e exclusões

Itens não comparáveis

O texto combinado de nome, categorias, gêneros e tags é pesquisado por playtest, demo, soundtrack, server, benchmark e editor. Esses itens não representam um jogo comercial completo e são removidos.

Validade mínima

Um registro precisa possuir data válida, não estar no futuro, possuir ponto médio de proprietários, possuir gênero e não estar marcado como item excluído.

Duplicatas

drop_duplicates usa Name, release_date e Developers. Essa chave evita contar novamente o mesmo jogo do mesmo desenvolvedor e lançamento.

Resultado

A base limpa atual contém 106,244 registros, cobrindo lançamentos entre 1998 e 2026.

6. Definição estatística de sucesso

Jogo comercial

`commercial_game` é verdadeiro quando o preço é maior que zero e menor ou igual a US\$ 100. Jogos gratuitos são analisáveis na base limpa, mas não participam do ranking comercial.

Vendas altas

`high_sales` exige `owners_midpoint` acima ou igual ao percentil 80 dos jogos pagos. No conjunto atual, esse limite é 35,000 proprietários estimados.

Boa avaliação

`well_rated` exige pelo menos 20 avaliações e `positive_ratio` de no mínimo 75%. O mínimo reduz casos em que uma ou duas avaliações positivas criariam uma nota enganosa.

Sucesso final

`success` = `commercial_game` AND `high_sales` AND `well_rated`. Portanto, sucesso combina alcance comercial e evidência mínima de satisfação.

Taxa-base

Entre os 89,000 jogos pagos analisados, 8,849 atendem aos critérios. A taxa-base é 9.94%.

7. Intervalo de confiança de Wilson

A taxa observada isolada pode favorecer grupos pequenos. O intervalo de Wilson estima uma faixa plausível para a taxa real de sucesso. O projeto usa $z = 1,96$, correspondente a aproximadamente 95% de confiança.

```
def intervalo_wilson(sucessos, total):
    z = 1.96
    taxa = sucessos / total
    denominador = 1 + z**2 / total
    centro = (taxa + z**2 / (2 * total)) / denominador
    margem = (
        z
        * np.sqrt(
            (taxa * (1 - taxa) + z**2 / (4 * total)) / total
        )
        / denominador
    )
    return centro - margem, centro + margem

ci_low, ci_high = intervalo_wilson(sucesses, games)
```

8. Resumo por grupos e evidence_score

Agregações

resumir_grupos calcula quantidade de jogos, quantidade de sucessos, taxa de sucesso, medianas de proprietários, preço, proporção positiva e avaliações.

Lift

$\text{lift_vs_baseline} = \text{success_rate} / \text{taxa_base}$. Um lift de 1,50 significa taxa de sucesso 50% superior à média dos jogos pagos analisados.

Evidence score

$\text{evidence_score} = \text{ci_low} \times \log(1 + \text{games})$. A parte ci_low favorece resultados cujo limite inferior ainda é forte. O logaritmo recompensa amostras maiores sem permitir que o volume domine completamente.

Ordenação

As tabelas são ordenadas primeiro por evidence_score, depois por success_rate e games. Portanto, o primeiro item representa combinação de desempenho e robustez, não apenas a maior porcentagem.

9. Campos multivalorados e correlações

Explosão de gêneros, tags e categorias

Um jogo pode possuir vários valores separados por vírgula. `resumo_expandido` divide a string em lista, remove espaços, usa `explode` e cria uma linha analítica por valor. Assim, um jogo RPG/Adventure participa dos dois resumos.

Correlação de Spearman

`correlacoes` mede associação monotônica entre proprietários e preço, pico CCU, avaliações, proporção positiva, recomendações, tempo médio, Metacritic e quantidade de plataformas.

Transformação logarítmica

Variáveis de volume recebem `log1p` porque distribuições de proprietários e avaliações são extremamente assimétricas. A transformação reduz a influência visual e numérica de grandes outliers.

Cuidado

Correlação não demonstra causalidade. Mais avaliações podem acompanhar mais vendas porque mais compradores geram avaliações; isso não prova que avaliações causam vendas.

10. Arquivos gerados por steam_calculo.py

Todos os arquivos abaixo são gravados em steam_analysis/. O Streamlit depende deles, exceto categories.csv, que permanece disponível para análises adicionais.

Arquivo	Linhas	Finalidade
steam_cleaned.csv	106,244	Base limpa por jogo
genres.csv	23	Resumo por gênero
tags.csv	377	Resumo por tag
categories.csv	48	Resumo por categoria
price_bands.csv	6	Resumo por faixa de preço
play_modes.csv	3	Resumo por modo de jogo
platforms.csv	3	Resumo por plataformas
release_years.csv	28	Resumo por ano
combinations.csv	163	Gênero + preço + modo + plataformas
correlations.csv	9	Correlações com proprietários

11. Função principal do pipeline

Orquestração

principal cria o diretório, repara a origem, limpa os dados, separa jogos pagos e calcula a taxa-base.

Tabelas simples

São produzidos resumos por gênero, tag, categoria, faixa de preço, modo de jogo, quantidade de plataformas e ano.

Combinações

O gênero é expandido e agrupado com price_band, play_mode e platform_count. Combinações com menos de 100 jogos são removidas para limitar conclusões frágeis.

Persistência

steam_cleaned.csv e cada tabela estatística são exportados. O script não contém recomendações de negócio; ele termina com um resumo curto de processamento.

Execução

Comando: `python steam_calculo.py`. Deve ser executado novamente quando steam_dataset.csv ou os critérios estatísticos mudarem.

12. Estrutura do dashboard Streamlit

Responsabilidade

`steam_streamlit.py` apresenta a camada de negócio. Ele não recalcula todo o pipeline; lê os CSVs prontos, aplica filtros de interface e constrói gráficos.

Configuração

`st.set_page_config` define título e layout amplo. As constantes de cor padronizam azul de destaque, verde de sucesso, cinza neutro e laranja de referência.

Cache

`carregar_dados` usa `@st.cache_data`. Após a primeira leitura, o Streamlit pode reutilizar os DataFrames e responder mais rapidamente às interações.

Proteção contra ausência

Antes de carregar, a função confirma que todos os arquivos necessários existem. Se faltarem arquivos, mostra orientação para executar `python steam_calculo.py` e interrompe o app.

13. Funções de visualização Matplotlib

limpar_eixos

Remove bordas superior e direita, adiciona grade horizontal e mantém os dados acima da grade. Isso cria identidade visual consistente.

grafico_barras_confianca

Exibe taxa de sucesso por gênero ou tag e adiciona barras de erro calculadas a partir de `ci_low` e `ci_high`.

grafico_barras_taxa

Compara grupos com a taxa-base. Barras acima da média ficam verdes; abaixo da média ficam cinza; a referência é uma linha laranja.

grafico_tendencia

Mostra a taxa por ano desde 2005, apenas com anos que possuem pelo menos 100 jogos. A área translúcida representa o intervalo de confiança.

grafico_combinacoes

Relaciona tamanho da amostra e taxa de sucesso. Tamanho da bolha depende da quantidade de jogos; cor depende do lift; cinco oportunidades recebem rótulo.

grafico_correlacoes

Apresenta associações de Spearman com proprietários estimados e remove `owners_midpoint`, que teria correlação perfeita consigo mesmo.

14. Sidebar, filtros e seleção da melhor oportunidade

Filtros

A barra lateral permite escolher gêneros, faixas de preço, modos de jogo, quantidade de plataformas e mínimo de jogos comparáveis.

Aplicação progressiva

Cada filtro selecionado reduz combinations.csv. Depois, o mínimo de jogos é aplicado e os resultados são ordenados por evidence_score e success_rate.

Fallback

Se nenhum filtro estiver ativo, o melhor resultado geral é usado. Se uma combinação de filtros não retornar linhas, o dashboard mostra aviso em vez de falhar.

Indicadores

Cinco métricas exibem jogos limpos, jogos pagos, taxa-base, limite de vendas altas e taxa da melhor combinação filtrada.

Interpretação

A recomendação executiva é deliberadamente apresentada no Streamlit, pois esta camada é responsável por comunicação de negócio.

15. Abas do relatório de negócio

Executive overview

Mostra gêneros com intervalo de confiança, faixas de preço, comparação multiplayer e cobertura de plataformas.

Opportunity explorer

Apresenta o gráfico de oportunidades, tabela formatada e botão para baixar apenas as combinações filtradas.

Market evidence

Mostra tags, correlações e tendência temporal. Inclui alertas para não interpretar tags retrospectivas como requisitos de produto.


Methodology

Explica definição de sucesso, abordagem estatística e limitações. Também oferece download da base analítica limpa.


Resultados usados pelo dashboard

Exemplos reais produzidos pelo pipeline atual


Taxa de sucesso por gênero



Taxa de sucesso por faixa de preço



Taxa de sucesso por modo de jogo



16. Principais combinações atuais

Esta tabela é um exemplo do conteúdo consumido pelo explorador de oportunidades. A ordem utiliza evidence_score, não somente success_rate.

Genre	price_band	play_mode	platform_count	games	success_rate	lift_vs_baseline	ci_low
Indie	\$0-5	Has multiplayer	3	667	26.2%	2.64x	23.0%
Action	\$0-5	Has multiplayer	3	505	25.1%	2.53x	21.6%
Simulation	\$10-20	Has multiplayer	1	418	26.1%	2.62x	22.1%
Strategy	\$0-5	Has multiplayer	3	217	30.4%	3.06x	24.7%
Strategy	\$5-10	Single-player only	3	265	28.7%	2.88x	23.6%
Simulation	\$20-30	Has multiplayer	1	109	34.9%	3.51x	26.6%
Indie	\$5-10	Single-player only	3	1069	19.8%	1.99x	17.6%
Indie	\$10-20	Has multiplayer	3	137	31.4%	3.16x	24.2%

17. Como interpretar os resultados atuais

Taxa-base

A referência para jogos pagos é 9.94%. Valores acima disso indicam associação positiva dentro do conjunto analisado.

Gênero

O RPG aparece no topo do ranking por evidência com taxa de 13.77% e lift de 1.38x.

Preço

A faixa \$10-20 aparece primeiro por evidência, com taxa de 14.89%. A faixa com maior taxa absoluta pode ser diferente porque tamanho e confiança também importam.

Multiplayer

Jogos com multiplayer possuem taxa observada de 14.89% e lift de 1.50x.

Decisão

Os resultados servem para formular e priorizar hipóteses. Eles devem ser combinados com custo de produção, capacidade da equipe, validação de demanda, wishlists, marketing e análise de concorrentes.

18. Limitações técnicas e estatísticas

Proprietários estimados

São faixas amplas, não vendas exatas. O ponto médio simplifica uma incerteza real.

Preço observado

O dataset pode refletir preço atual e descontos, não necessariamente preço de lançamento.

Variáveis ausentes

Não existem custos de desenvolvimento, orçamento de marketing, reputação prévia, tamanho da equipe ou receita líquida.

Viés e causalidade

A análise é observacional. Jogos bem-sucedidos podem receber ports e mais avaliações depois do sucesso. Portanto, associação não prova causa.

Tags

Tags como Classic e Cult Classic descrevem percepção ou resultado retrospectivo. Não são funcionalidades que podem ser escolhidas diretamente.

Critérios ajustáveis

Percentil 80, 20 avaliações, 75% positivo, preço máximo de US\$ 100 e mínimo de 100 jogos são decisões explícitas. Alterá-las muda os resultados.

19. Como executar e revisar

Requisitos

Python com pandas, numpy, matplotlib e streamlit. O arquivo `steam_dataset.csv` deve estar no mesmo diretório dos scripts.

Passo 1

Execute `python steam_calculo.py`. Confirme a criação de `steam_analysis/` e dos CSVs. O console deve informar jogos limpos, jogos pagos e diretório de saída.

Passo 2

Execute `streamlit run steam_streamlit.py`. O navegador abrirá o dashboard.

Passo 3

Teste filtros individuais e combinações. Confirme que a tabela e a melhor oportunidade mudam. Use os botões de download.

Passo 4

Revise metodologia e limitações antes de apresentar recomendações. Não trate taxas observadas como garantia de retorno.

20. Checklist de revisão de código

steam_calculo.py

Verificar se o reparo do cabeçalho continua válido para uma nova versão do dataset; confirmar datas e faixas de proprietários; revisar critérios de exclusão; validar definição de sucesso; comparar contagens antes e depois da limpeza; verificar duplicatas e ausências.

Estatísticas

Confirmar taxa-base; inspecionar grupos pequenos; conferir intervalos de Wilson; revisar evidence_score; avaliar sensibilidade a critérios diferentes; evitar interpretação causal.

Streamlit

Confirmar presença dos CSVs; testar cache; testar filtros vazios e sem resultados; verificar legibilidade dos gráficos; conferir downloads; revisar textos executivos quando os dados forem atualizados.

Operação

Regenerar CSVs antes de abrir o dashboard após mudanças no pipeline. Manter os nomes de colunas persistidas porque o Streamlit depende desse contrato.

21. Glossário das principais colunas

owners_midpoint

Ponto médio entre os limites inferior e superior da faixa de proprietários estimados.

positive_ratio

Avaliações positivas divididas pelo total de avaliações.

commercial_game

Jogo pago com preço maior que zero e até US\$ 100.

high_sales

Jogo no percentil 80 ou superior de proprietários entre jogos pagos.

well Rated

Jogo com pelo menos 20 avaliações e 75% positivas.

success

Interseção de commercial_game, high_sales e well Rated.

success_rate

Quantidade de sucessos dividida pela quantidade de jogos do grupo.

lift_vs_baseline

Taxa do grupo dividida pela taxa-base dos jogos pagos.

ci_low / ci_high

Limites inferior e superior do intervalo de confiança de Wilson.

evidence_score

Pontuação de ordenação que combina limite inferior de confiança e tamanho da amostra.

Conclusão

Separação correta

steam_calculo.py é uma camada reproduzível de engenharia de dados e estatística. steam_streamlit.py é uma camada de apresentação, exploração e comunicação de negócio.

Força do projeto

Os critérios estão explícitos, as saídas são persistidas, a incerteza é considerada por intervalos de confiança e grupos pequenos são controlados.

Próxima revisão recomendada

Validar os critérios de sucesso com a realidade financeira da empresa. Se houver dados de orçamento, marketing e receita, incorporá-los para aproximar a análise de lucratividade, não apenas de alcance e avaliação.